

## 基于深度学习的物流需求预测模型研究

李国祥<sup>1,2,3</sup> 马文斌<sup>1,2</sup> 夏国恩<sup>1,3</sup>

(1. 广西财经学院 教务处 广西 南宁 530003;

2. 广西师范大学 广西多源信息挖掘与安全重点实验室 广西 桂林 541004;

3. 广西财经学院 广西跨境电商智能信息处理重点实验室培育基地 广西 南宁 530003)

**摘要:**新一轮的科技革命和经济结构的不断优化对于区域物流需求的预测提出了更高的要求。本文以 LSTM 为研究对象,提出了基于深度学习的区域物流预测模型。从预测模型数据结构的角  
度,在时间序列和影响因子两个层面上,将深度学习预测模型与传统统计学方法、神经网络方法,基于优化寻参的支持向量回归机等方法进行综合对比评估。仿真结果表明,基于时间序列数据源的预测模型普遍优于影响因子数据源模型,而基于 LSTM 区域物流预测模型具有良好的预测性能,平均绝对百分误差 4% 左右,且稳定性好。

**关键词:** 物流预测; 时间序列; 影响因子; LSTM

**中图分类号:** N949 **文献标识码:** A **文章编号:** 1005-6408(2021)02-0085-05

区域物流需求的定量分析对于各种区域物流发展政策、区域物流规划有着重大意义。纵观当前关于物流需求预测方法的研究,主要分为以下几类:

(1) 传统的统计学方法,即灰色理论模型、多元回归模型、ARIMA 模型等;(2) 基于神经网络的预测方法,即 BPNN(反向传播神经网络),RBF 神经网络,MLP(多层感知器),GRNN(广义回归神经网络)等;(3) 支持向量机的预测方法,其中惩罚系数和径向基核函数 gamma 的选择是关键,由此延伸了众多寻优算法优化的支持向量机,即(Grid Search)网格划分<sup>[1]</sup>,GA(遗传算法)<sup>[2]</sup>,PSO(粒子群算法)<sup>[3]</sup>等;(4) 上述方法的多种集成融合。文献[4]建立了灰色模型与前馈人工神经网络的组合模型,文献[5]则集成了 RBF 神经网络和 ARIMA 模型,同时定性分析难以量化的外部因素。文献[6]使用复合核函数代替单一核函数的支持向量机实现数据的拟合预测。文献[2]利用遗传算法(GA)优化支持向量回归(SVR)机选参,形成预测模型。可以看出,近年来的目标预测算法研究,主要集中在与支持向量机为代表的机器学习算法上,传统统计学方法作为单一

的预测方法已逐渐地失去优势,常以集成的方式融入到其他方法中。

另一方面,从预测数据的选择上又可以将其分为两类:一类选取与目标变量强关联的属性变量作为预测数据源,该类数据结构理论上认为物流需求是由多维属性变量建立线性或非线性关系共同作用的结果。该类数据的选择主要考虑了物流需求与各指标影响因子间的关联关系,通过机器学习算法建立二者间映射关系并拟合。比如,文献[7]选取了第一产业产值等六个指标作为港口物流需求预测的影响因子,文献[6]使用 GDP,社会物流总费用等 11 个影响因子开展预测。文献[8-9]以经济因素、行业因素、环境因素和其他因素为一级指标,分别建立了共 27 个和 33 个的区域物流需求影响因素指标体系。另外一类预测数据源则直接对物流需求目标变量建立时间序列,通过回溯历史数据来进行未来时间轴上数据的预测<sup>[10]</sup>。该类数据结构单一简单,形成了完整有效的时间链条,在未来节点有更好的可拓展性。文献[2]在货运量时间序列上,利用前四个节点的实际数据来预测下一个节点的需求。文献

收稿日期: 2019-07-05

基金项目: 国家自然科学基金(71862003); 广西重点研发计划(2018AB15003); 广西跨境电商智能信息处理重点实验室培育基地(广西财经学院)专项资助项目; 广西多源信息挖掘与安全重点实验室开放基金项目(MIMS17-02); 广西高校中青年教師基礎能力提昇項目(2018KY0520); 广西财经学院青年教师科研发展基金(2018QNA02)

作者简介: 李国祥(1984-),男,山东济宁人,广西财经学院副教授,广西师范大学工学硕士,研究方向: 模式识别,商务智能。

[11]使用 ARIMA 模型在公路物流运价指数的时间序列上开展预测。

近年来,深度学习作为一种新的机器学习算法在图像识别、语音识别、自然语言处理等人工智能领域有着广泛地应用,尤其是图像领域,2012 年 CNN 网络 AlexNet<sup>[12]</sup> 在 ImageNet 比赛中突出的表现,使得 CNN 的研究成为热点,并延伸出众多分类性能更为突出的深度学习网络 VGG<sup>[13]</sup>、GoogLeNet<sup>[14]</sup>、ResNet<sup>[15]</sup>,随着模型深度不断增长,百万级当量数据集 Top-5 的错误率降到了 3.5% 附近,已经超过了人眼识别精度。鉴于其优良的学习性能,深度学习也开始广泛地应用于目标变量的预测中<sup>[16-19]</sup>。但是目前在物流需求预测领域,模型的建立仍然以支持向量回归机为主,深度学习网络研究尚为数不多,为此,本文提出了基于长短期记忆网络( Long Short - Term Memory, LSTM) 的物流预测方法,并从数据结构的角度与支持向量回归机等方法进行了深入比较。

## 1 循环神经网络

与传统神经网络相同,循环神经网络( recurrent neural network, RNN) 通常也是由输入层、隐藏层和输出层构成。但与传统神经网络不同的是 RNN 的隐藏层单元之间存在基于时间序列的回环,上一时刻的输出可以作为当前时刻的输入。因此,RNN 可以将长期信息依次传递并影响网络的最终输出。简单的 RNN 结构如图 1 所示。 $x$  表示输入序列, $U$  是输入层到隐藏层的权重, $s$  是隐藏层输出值, $W$  是上一时刻输出到当前时刻输入的权重, $V$  是隐藏层到输出层的权重向量, $o$  表示输出层的输出向量。

RNN 隐藏层单元间的连接结构如图 2 所示。在  $t$  时刻,隐藏层单元的输入是  $s_{t-1}$  和  $x_t$ ,隐藏层单元的值是  $s_t$ ,输出是  $o_t$ 。

由图 2 可知,RNN 的前向计算过程可以用公式(1)~公式(2)表示。

$$s_t = f(W_{hh} \cdot s_{t-1} + W_{hx} \cdot x_t + b_s) \quad (1)$$

$$o_t = \sigma(W_{ho} \cdot s_t + b_o) \quad (2)$$

## 2 长短期记忆网络

RNN 通常以随时间反向传播( Back - Propagation Through Time, BPTT) 算法作为训练方法,当输入序列较长时,存在梯度消失的问题,无法处理长期依赖问题。Hochreiter 等<sup>[20]</sup> 通过引入门控单元,提出的长短期记忆模型,能够有效解决 RNN 训练过程中存在的长期依赖问题。LSTM 结构如图 3 所示。




图1 RNN 结构图




图2 RNN 隐藏层单元结构

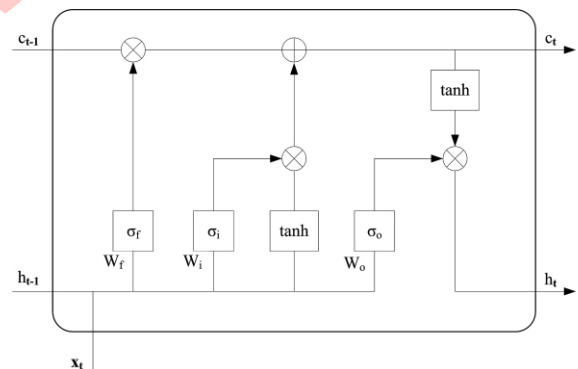


图3 LSTM 模型结构

由图 3 可知,在  $t$  时刻,LSTM 单元有三个输入,分别是输入序列  $x_t$ 、上一步的输出  $h_{t-1}$  和 LSTM 单元状态  $c_{t-1}$ ; 有两个输出,  $h_t$ 、 $c_t$ ; 内部有三个门控,分别是遗忘门  $f$ 、输入门  $i$  和输出门  $o$ 。LSTM 通过三个门控单元实现长期信息的状态控制。

遗忘门和输入门决定 LSTM 的单元状态  $c_t$ 。其中,遗忘门决定上一时刻的 LSTM 单元状态  $c_{t-1}$  的哪些信息要保留在  $c_t$ ,输入门决定当前输入序列  $x_t$  的哪些信息要保留在  $c_t$ 。遗忘门、输入门的值如式(3)、式(4)所示。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (4)$$

其中,  $\sigma$  为 Sigmoid 函数, 是神经网络中常用的激活函数, 可将变量映射到 0 ~ 1 之间。当门的输出值是 0 时, 表示舍弃所有信息, 当门的输出值是 1 时, 表示保留所有信息。

当前输入的单元状态  $c_t$ , 与上一时刻的输出和当前时刻的输入有关, 计算方法如式 (5) 所示:

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (5)$$

当前时刻的单元状态  $c_t$  的值是关于  $f_t$ 、 $i_t$ 、 $c_t$  和  $c_{t-1}$  的函数, 计算方法如式 (6) 所示:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (6)$$

其中,  $\odot$  表示按元素相乘。

输出门决定当前时刻的单元状态的哪些信息可以输出, 控制长期记忆对当前输出的影响, 输出门的计算如式 7 所示, LSTM 单元在  $t$  时刻的最终输出如式 (8) 所示:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (7)$$

$$h_t = o_t \odot \tanh(c_t) \quad (8)$$

### 3 基于 LSTM 的物流需求预测

我们选取广西 1990—2016 年的货运量作为物流需求的目标变量, 分别从影响因子和时间序列两个层面上开展物流预测的实证研究。影响因子以文献 [9] 构建的指标体系作为目标预测的属性变量, 考虑到数据的完整性, 从 33 个指标中选择较为完整的 20 个指标作为影响因子。通过多次重复试验, 在两种数据结构上将预测模型与传统统计学方法代表 [GM(1, 1)], 神经网络算法代表 (GRNN), 基于优化寻优的支持向量回归机代表 (Grid Search SVR, GA SVR, PSO SVR), 属性约简的支持向量回归机 (PCA SVR) 进行对比试验。实验中统一使用 1990—2011 年货运量及其所对应的影响因子作为

表 1 基于时间序列的区域物流预测

Year	Observed Value	Grid Search SVRbestc = 9.19; bestg = 0.33		GA SVR bestc = 16.05; bestg = 0.43		PSO SVR bestc = 29.52; bestg = 0.10		LSTM HiddenUnits = 46	
		Predicted Value	Percentage Error	Predicted Value	Percentage Error	Predicted Value	Percentage Error	Predicted Value	Percentage Error
2012	161368	153940.4	-4.60%	147209.9	-8.77%	162484.3539	0.69%	150590.3	-6.68%
2013	151155	158349.9	4.76%	144728.6	-4.25%	180230.1519	19.24%	155372.9	2.79%
2014	163043	147568.4	-9.49%	132293	-18.86%	173559.607	6.45%	156796.6	-3.83%
2015	149727	142739.7	-4.67%	125319.2	-16.30%	177249.0488	18.38%	157103.5	4.93%
2016	160761	135889.2	-15.47%	119642.1	-25.58%	170697.8202	6.18%	156740.7	-2.50%

#### 3.2 基于影响因子的预测方法

采用影响因子数据源来进行预测, 预测模型维

训练集, 2012—2016 年货运量及其所对应的影响因子作为测试集, 并对原始输入数据归一化, 预测完成后逆向处理, 得到预测值。鉴于当前机器学习算法的强学习能力, 本文不再讨论算法的拟合度, 统一使用 2012—2016 年的预测值而非拟合值来保证实验的实际有效。计算平均绝对百分误差 (Mean Absolute Percentage Error, MAPE) 和标准误差 (Root Mean Square Error, RMSE) 两个指标, 评价其预测精度。

#### 3.1 基于时间序列的预测方法

参考文献 [2], 我们同样采用前四年的货运量数据来预测第五年的物流需求, 即形成四维度输入一维度输出的预测模型。对于 LSTM 预测模型, 我们首先对不同隐层单元预测效果进行评估, 不同的隐层单元对于预测精度的影响是不同的, 这里我们遍历了 200 以内的隐层单元, 其结果如图 4 所示, 隐层单元在 20 ~ 65 区间整体表现趋于稳定, 且 MAPE 保持在 5% 以下, 具有较好的预测效果, 随着隐层单元的继续增加, 误差逐渐增加。因此我们选取 46 个隐层单元作为 LSTM 的隐藏层。迭代次数 250 次, 步长为 1, 初始学习率 0.005。

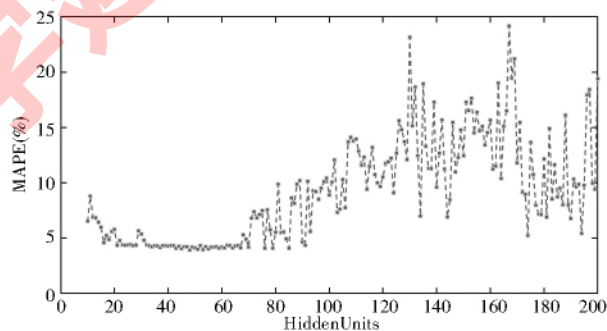


图 4 不同隐层单元预测精度的比较

根据上述设置, 将 LSTM 的预测模型与支持向量回归机系列模型进行详细对比。区域物流需求的预测结果如表 1 所示。

度则为 20 维输入一维度输出, LSTM 隐层单元根据训练结果设定为 70, 预测结果如表 2 所示。



表 2 基于时间序列的区域物流预测

Year	Observed Value	Grid Search SVR bestc = 48.50; bestg = 0.0039		GA SVR bestc = 2.78; bestg = 0.09		PSO SVR bestc = 1.37; bestg = 0.10		LSTM HiddenUnits = 70	
		Predicted Value	Percentage Error	Predicted Value	Percentage Error	Predicted Value	Percentage Error	Predicted Value	Percentage Error
2012	136132	114289.6	-16.05	112435.6	-17.41	112045.3	-17.69	140802	3.43
2013	161368	139313.4	-13.67	140938.3	-12.66	137408	-14.85	143699	-10.95
2014	151155	154681.8	2.33	151520.1	0.24	145135.8	-3.98	142707	-5.59
2015	163043	165861.6	1.73	156636.8	-3.93	148649.2	-8.83	143252	-12.14
2016	149727	174281.3	16	157861.2	5.43%	148593.2	-0.76	143419	-4.21

### 3.3 预测模型的稳定性检测

鉴于粒子群等算法的参数优化是随机的,LSTM 的相同参数所得到预测结果也略有差异,为了更好地检验不同算法的稳定性,随机重复试验 100 次,验证 GM(1,1),GRNN,Grid Search SVR,GA SVR,PSO SVR,PCA SVR 等算法的可靠程度,形成误差直方图,见图 5、图 6。




图 5 各模型在不同数据源的 MAPE 对比




图 6 各模型在不同数据源的 RMSE 对比

通过多次试验可以看出,从数据结构的角度来看,时间序列的数据源预测效果整体要优于影响因子数据源的效果,无论是从全数据面板的指标体系还是经过降维后的影响因子,其预测效果都略低于时间序列中的同类方法水平。这说明区域物流影响因素众多,学习样本的选择无论是主观的定性分析还是客观的模型验证,系统的复杂性尚不足优于实际物流需求的时间序列结构。从预测方法的角度看,又因为数据结构的不同而略有差异。在影响因子的预测方法中,SVR 系列方法预测效果是较好的,优于其他几种方法。其主要原因在于 SVR 优秀的泛化能力,结构风险最小化的原理使得其对于多

维数据的拟合效果较好。基于 GRID,PCA + GRID, PSO 寻优的 SVR 的 MAPE 稳定在 10% 左右,其中预测效果最佳的 PSO - SVR 的 MAPE 为 9.04%,GA 寻优算法仅略胜于 GRNN。在时间序列中的预测方法中 LSTM 预测效果表现突出,MAPE 仅为 4.199%,高出 SVR 优化系列中最优的 Grid SVR 近 4 个百分点,高出 GRNN 近 10 个百分点,且在 100 次的随机试验中表现稳定,标准差仅为 0.101。PCA + GRID,PSO SVR 则预测效果一般,MAPE 在 12% - 16% 之间。

### 结论

实验证明,时间序列的数据结构相对于影响因子数据结构具有更好的可靠性,依赖于 LSTM 在时间序列上的长短期记忆而实现的信息取舍优势,其预测模型具有良好的预测性能,平均绝对百分误差 4% 左右,且稳定性好。

### 参考文献

- [1] 王兴玲,李占斌.基于网格搜索的支持向量机核函数参数的确定[J].中国海洋大学学报(自然科学版),2005(5):859-862.
- [2] 曹志强,杨笋,刘放.基于遗传算法优化支持向量回归机的区域物流需求预测[J].系统科学学报,2018,26(4):79-82+90.
- [3] 唐贤伦,李洋,李鹏,等.多智能体粒子群优化的 SVR 模型预测控制[J].控制与决策,2014,29(4):593-598.
- [4] 张乐,汪传旭.基于 GM(1,1)-MLP 神经网络组合模型的物流总额预测[J].上海海事大学学报,2018,39(4):58-62.
- [5] 金淳,淳迪,王聪,等.汽车零部件第三方物流仓储需求集成预测模型[J].系统管理学报,2018,27(6):1157-1165.
- [6] 范思遐,吴斌.基于复合核模的物流需求预测研究[J].工业工程与管理,2018,23(2):40-44.
- [7] 蔡婉贞,黄翰.基于 BP 和 RBF 神经网络组合模型的港口物流需求预测研究[J].郑州大学学报(工学版),2019(5):1-7.
- [8] 余彩艳.中部地区物流需求的实证分析[D].南昌:南昌大学,2008.
- [9] 李国祥,夏国恩,高荣,等.基于属性约简的区域物流需求预测[J].计算机应用与软件,2013,30(11):60-63+160.
- [10] 李国祥,夏国恩,王继军.多维数据特征相似性测量的目标预测方法[J].统计与决策,2018,34(9):15-19.
- [11] 原云霄,王宝海.基于 ARIMA 模型对我国公路物流运价指数的

- 预测[J]. 数学的实践与认识, 2017, 47(23): 52-57.
- [12] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks [C] // Proceedings of the International Conference on Neural Information Processing Systems, 2012, 1097-1105.
- [13] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [J]. arXiv, 2014, 1409: 1566.
- [14] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions [C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.
- [15] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [16] 陈卫华, 徐国祥. 基于深度学习和股票论坛数据的股市波动率预测精度研究[J]. 管理世界, 2018, 34(1): 180-181.
- [17] 黄立群, 丁雪松, 张步忠, 等. 一个深度学习 DNA 序列特异性的预测模型[J]. 小型微型计算机系统, 2018, 39(11): 2424-2427.
- [18] 刘明宇, 吴建平, 王钰博, 等. 基于深度学习的交通流量预测[J]. 系统仿真学报, 2018, 30(11): 4100-4105 + 4114.
- [19] 权波, 杨博辰, 胡可奇, 等. 基于 LSTM 的船舶航迹预测模型[J]. 计算机科学, 2018, 45(S2): 126-131.
- [20] Hochreiter S, Schmidhuber J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.

## Research on Logistics Demand Forecast Mode Based on Deep Learning

LI Guo-xiang<sup>1,2,3</sup> MA Wen-bin<sup>1,2</sup> XIA Guo-en<sup>1,3</sup>

(1. Department of Academic Affairs, Guangxi University of Finance and Economics, Nanning 530003, China;

2. Guangxi Key Lab of Multi-source Information Mining and Security, Guangxi Normal University, Guilin 541004, China;

3. Guangxi Key Laboratory Cultivation Base of Cross-border E-commerce Intelligent Information Processing, Guangxi University of Finance and Economics, Nanning 530003, China)

**Abstract:** With the revolution of technology and economic structure optimization, higher requirements are put forward for the prediction of regional logistics demand. In this paper, a regional logistics forecasting model based on LSTM deep neural network is proposed. There are two data structures in the prediction model: time series and impact factors. Based on the above two data structures, different methods are compared, such as traditional statistical methods, neural network methods and optimized support vector regression. The experimental results show that prediction models based on time series are generally superior to impact factor data models, and the LSTM deep neural network can control the prediction error within 4% with stability.

**Key words:** logistics forecasting; time series data; impact factor data; LSTM

(上接第 84 页)

## Psychological System Analysis of the Acceptance of Ideological and Political Education

JING Wei-guo<sup>1,2</sup> KUANG Zhi-hua<sup>2</sup>

(1. School of Internet of Things, Wuxi Institute of Technology, Wuxi 214121, China;

2. Academy of Marxism, Nanjing University of Science and Technology, Nanjing 210094, China)

**Abstract:** The psychosocial system analysis accepted by ideological and political education is based on the perspective of social ecology, psychological theory and method, and accepts the operational rules and mechanism of the interaction and interaction of different elements of the subject's psychological structure and the elements of the acceptance process. From the perspective of the accepted psychosocial ecosystem, the social psychological system of ideological and political education can be divided into: social initiation system, psychological guidance system, empathy adjustment system, action enhancement system, and ability migration system to enrich the theoretical achievements of ideological and political education.

**Key words:** ideological and political education; acceptance process; psychological system analysis; elements