

蚁群优化支持向量机的物流需求预测^①

孙志刚

(浙江传媒学院, 浙江 杭州 310018)

摘 要: 为了提高物流需求预测精度, 针对物流需求的复杂变化特性, 提出一种蚁群算法(ACO)优化最小二乘支持向量机的(LSSVM)的物流需求预测模型(ACO-LSSVM)。首先对物流需求数据进行重构, 然后采用 LSSVM 刻画物流需求的复杂非线性变化特性, 并通过 ACO 算法优化选择 LSSVM 参数, 采用物流需求预测实例对 ACO-LSSVM 性能进行测试。结果表明, ACO-LSSVM 提高了物流需求预测精度, 是一种有效的物流需求预测方法。

关键词: 物流需求; 蚁群优化算法; 最小二乘支持向量机; 预测

Logistics Demand Forecasting Based on Least Support Vector Machine Optimized by Ant Colony Optimization Algorithm

SUN Zhi-Gang

(Zhejiang University of Media and Communications, Zhejiang 310018, China)

Abstract: In order to improve the forecasting accuracy of logistics demand, this paper puts forward a logistics demand forecasting model based on least support vector machines optimized by ant colony optimization algorithm (ACO-LSSVM). Firstly, the data of logistics demand are reconstructed, and then the complex nonlinear change rule of logistics demand is explained through LSSVM, and the parameters of LSSVM model are optimized by ACO, and lastly, the performance of mode are tested by logistics demand data. The simulation results show that ACO-LSSVM has improved the forecasting accuracy of logistics demand, and which is an effective method for logistics demand forecasting.

Key words: logistics demand forecasting; ant colony optimization algorithm; least support vector machine; prediction

1 引言

物流需求受到如经济、政策、资源等因素的影响, 导致物流需求具有非平稳性和随机性, 物流需求呈现高度非线性变化趋势, 数学模型难以对其进行准确描述, 且我国物流业发展水平较低, 数据严重缺乏, 目前物流需求预测精度与实际要求有一定的差距^[1]。

传统物流需求预测方法假设物流需求是一种线性变化规律, 难以刻画复杂物流需求变化特征性^[2]。神经网络具有强大的非线性拟合能力和泛化能力, 可以逼近物流需求与影响因素间非线性关系, 广泛应用于物流需求预测中^[3,4]。在实际应用中, 神经网络易出现局部极小值和收敛速度慢等缺陷^[5]。最小二乘支持向量机(LSSVM)较好克服了神经网络存在的缺陷, 适用

于小样本、非线性物流需求问题预测, 并取得了较好的研究效果^[6]。然而 LSSVM 的预测精度依赖于核函数选择及参数优化, 目前主要采用遗传算法(GA)和粒子群优化算法(PSO)对参数进行优化, 一定程度上提高了 LSSVM 的预测性能^[7,8]。但是 GA 和 PSO 算法均存在不同程度的缺陷, 如收敛速度慢、易陷入局部极小值, 难以找到全局最优 LSSVM 参数, 限制了 LSSVM 在物流需求预测应用^[9]。

为了提高物流需求预测精度, 将蚁群优化算法(ACO)和 LSSVM 相融合, 提出一种 ACO 优化 LSSVM 参数的物流需求预测模型(ACO-LSSVM)。结果表明, 相对于其它预测模型, ACO-LSSVM 对物流需求具有较好的非线性拟合能力, 预测精度更高。

^① 收稿时间:2012-10-19;收到修改稿时间:2012-11-29

2 ACO-LSSVM的物流需求预测模型

2.1 LSSVM 算法

对于一物流样本集 $\{(x_i, y_i)\}, i=1, 2, \dots, n$, x_i 和 y_i 为 LSSVM 的输入和输出, $x_i \in R^n, y_i \in R$. LSSVM 建模预测实际就是通过非线性映像函数 $\varphi(\cdot)$ 将物流需求数据映像到高维特征线性空间进行预测, 即:

$$f(x) = w^T \varphi(x) + b \quad (1)$$

式中, w 为权值值, b 为偏置向量.

对于式(1)的系数, LSSVM 通过结构风险最小化原则进行求解, 即有:

$$\min \|w\|^2 + \frac{1}{2} \gamma \sum_{i=1}^n \zeta_i^2 \quad (2)$$

s.t.

$$y_i - w^T \varphi(x) + b = e_i, (i=1, 2, \dots, n)$$

式中, γ 为惩罚参数, e_i 为预测误差.

对式(2)直接进行求解相当困难, 因此通过引入拉格朗日乘子将其转化无约束优化问题, 即:

$$L(w, b, \zeta, \alpha) = \min \|w\|^2 + \frac{1}{2} \gamma \sum_{i=1}^n \zeta_i^2 + \sum_{i=1}^n \alpha_i (w^T \varphi(x) - b + e_i - y_i) \quad (3)$$

式中, α_i 为拉格朗日乘子.

对于非线性回归问题, 需要引入 $K(x_i, x_j)$, 核函数定义为:

$$K(x_i, x_j) = \varphi(x_i)^T \varphi(x_j) \quad (4)$$

由于大多数情况下, 向基核函数(RBF)的通用性要强于其它核函数, 因此, 本研究用 RBF 作为 LSSVM 的核函数, RBF 定义如下:

$$k(x_i, x_j) = \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right) \quad (5)$$

从而得到基于 LSSVM 的物流需求预测模型为:

$$f(x) = \sum_{i=1}^N \alpha_i \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right) + b \quad (6)$$

式中, σ 表示径向基核数宽度^[10].

2.2 影响混沌时间序列预测结果的参数分析

对于同一时间序列, LSVSVM 在不同的参数(γ 和 σ)下的预测精度比较如表 1 所示.

表 1 参数对 LSSVM 预测性能的影响

γ	σ	MSE
1	0.001	0.713
10	0.01	0.974
100	0.1	0.185
1000	1	0.255
1000	10	0.295
10000	100	0.398

从表 1 可知, 参数(γ 和 σ)对预测结果的影响均很大, 要得到预测性能的 LSSVM 模型, 必须对参数(γ 和 σ)进行优化. 蚁群算法(ACO)一种的仿生类算法, 其模拟蚂蚁的寻找食物特性, 通过正反馈搜索机制, 实现对组合优化问题求寻, 在旅行商问题、调度问题得到广泛应用^[11]. 为此, 本研究采用 ACO 优化 LSSVM 的参数(γ 和 σ), 以得到具有全局最优的 LSSVM 预测模型.

2.3 蚁群算法设计

(1) 蚁群位置和信息素的初始化. 设蚁群规模为 N , 随机确定蚁群在解空间的初始位置, 然后根据 LSSVM 参数范围计算蚂蚁 i 的初始信息素浓度, 即:

$$\Delta \tau(i) = \exp(-f'(x_i)) \quad (7)$$

根据式(7)可知, 当 $f(x_i) \geq 0$ 时, 且无穷大时, 信息素浓度将接近零, 因此, 在该种情况下需求修正蚂蚁的适应度 $f(x_i)$ 值.

$$f'(X_i) = \begin{cases} f(X_i) / \text{avg}, & \text{if } \text{avg} > \text{avg}_0 \\ f(X_i), & \text{otherwise} \end{cases} \quad (8)$$

式中, $f(x_i)$ 和 $f'(x_i)$ 分别为修正前后的适应度值, avg 为 $f(x_i)$ 的平均值.

(2) 蚂蚁路径转移规则. 当每一只蚂蚁在完成一次搜索后, 均要根据路径转规则选择下一次搜索方向, 本研究搜索方式为:

首先随机从蚁群选择 k 只蚂蚁, 然后从选择的 k 只蚂蚁中抽取的个体中信息素浓度最大者作为转移目标 X_{obj} .

$$X_{obj} = \begin{cases} X_j, & \text{if } \tau(X_i) < \max(\tau(X_j)) \\ X_{best}, & \text{otherwise} \end{cases} \quad (9)$$

式中, X_{best} 表示上次迭代中获得的最优解.

由于信息素浓度越大对其它蚂蚁的吸引程度就越大, 从而使蚁群找到最优解的概率就越大, 这样蚂蚁 i

就会按式(10)向目标蚂蚁位置聚集:

$$X_i = (1 - \lambda)X_i + \lambda X_{obj} \quad (10)$$

完成上述搜索后,就可以得到上次迭代最优解的蚂蚁 X_{best} , 然后在该蚂蚁的邻域内进行进一步的精细搜索, 即:

$$X_{best} = \begin{cases} X'_i, & \text{if } f(X'_i) < f(X_{best}) \\ X_{best}, & \text{otherwise} \end{cases} \quad (11)$$

(3) 信息素浓度更新策略. 每完成一次局部搜索后, 均需要更新蚂蚁 i 的信息素浓度 $\tau(i)$, 具体更新方式为:

$$\tau(i) = (1 - \rho)\tau(i) + \Delta\tau(i) \quad (12)$$

式中, ρ 表示信息素挥发系数.

3 ACO-LSSVM的物流预测模型

ACO-LSSVM 的物流预测模型的工作步骤.

Step1: 收集物流需求历史数据, 并对其进行相应预处理, 具体预处理如下:

$$\square y_i = \frac{y_i - \min(y_i)}{\max(y_i) - \min(y_i)} \quad (14)$$

式中, y_i 表示第 i 个物流数据, $\max()$ 和 $\min()$ 表示取最大值和最小值函数.

Step2: 通过确定嵌入维数对原始物流需求数据进行重构.

Step3: 设置蚁群算法参数, 并初始化蚂蚁位置, 每个位置向量对应于 LSSVM 的参数 γ 和 σ .

Step4: 训练集输入到 LSSVM 中进行学习, 以训练集预测误差作为蚂蚁的适应度值, 计算蚂蚁的信息素浓度.

Step5: 随机抽取 p 只蚂蚁, 根据每只蚂蚁所在位置的信息素浓度大小, 找出最优蚂蚁的位置设为 X_{best} , 把它作为目标个体 X_{obj} .

Step6: 种群中非最优蚂蚁按式(10)向目标蚂蚁位置移动进行全局搜索.

Step7: 根据式(11), 最优蚂蚁在其邻域内进行精细搜索.

Step8: 对每只蚂蚁, 根据式(12)更新其信息素浓度.

Step9: 如果达到最大迭代次数, 就可以将最优蚂蚁位置反编码, 得到 LSSVM 参数 γ 和 σ 的最优值.

Step10: 根据得到的最优 LSSVM 参数 γ 和 σ 的最优值建立最优物流需求预测模型.

4 实验分析

4.1 资料来源

为了验证 ACO-LSSVM 对物流需求的预测性能, 采用 1992~2007 年湖南省货运量进行仿真测试, 数据具体如图 1 所示. 1992~2002 年的数据作为训练样本集, 2003~2007 年的数据作为测试样本集.

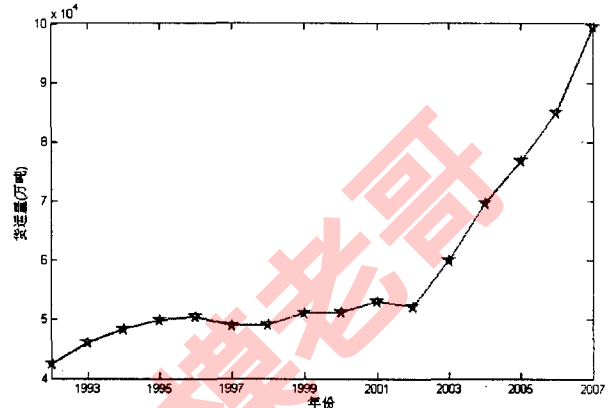


图1 1992~2007年湖南省货运量

4.2 对比模型和评价指标

为了使 ACO-LSSVM 预测结果更具说服力, 选择网络优化 LSSVM(LSSVM)、GA 优化 LSSVM(GA-LSSVM) 和 PSO 优化 LSSVM(PSO-LSSVM) 作为对比模型. 所有模型均采用一步预测方法. 模型性能评价体系采用方根误差(RMSE)、相对百分比误差(MAPE)和搜索参数花费时间(TIME).

4.3 结果与分析

采用 PSO、GA、ACO 对 LSSVM 参数进行优化, 其适应度函数变化曲线如图 2 所示, 它们所得到的最优参数见表 2 所示. 从图 2 可知, ACO 的收敛速度明显要快于 PSO、GA, 同时获得的适应度函数值要优于 PSO、GA, 从而获得了更优的 LSSVM 参数, 克服了 PSO、GA 收敛速度慢, 易获得局部最优 LSSVM 参数灵敏的缺陷.




图2 PSO、GA、ACO 的收敛曲线

表 2 PSO、GA、ACO 获得 LSSVM 参数

LSSVM 参数优化算法	γ	σ
GA	100	1.625
PSO	612	1.910
ACO	500	1.127

采用表 2 的 LSSVM 参数, 建立相应的 GA-LSSVM、PSO-LSSVM、ACO-LSSVM 的物流需求预测模型, 并采用各模型的对测试样本集的预测结果如表 3 所示。从表 3 可知, 在所有模型的中, ACO-LSSVM 的预测值与实验最为接近, 其更能准确刻画复杂物流需求变化趋势, 是一种有效的物流需求预测方法。

表 3 各模型的预测值与实际值对比

年份	实际值	LSSVM		GA-LSSVM		PSO-LSSVM		ACO-LSSVM	
		预测值	相对误差	预测值	相对误差	预测值	相对误差	预测值	相对误差
2003	59952	60864	1.52%	59795	-0.26%	59563	-0.65%	59860	-0.15%
2004	69680	69934	0.36%	69578	-0.15%	69868	0.27%	69723	0.06%
2005	76876	77281	0.53%	76941	0.08%	77013	0.18%	76849	-0.04%
2006	84998	85133	0.16%	84299	-0.82%	84332	-0.78%	85105	0.13%
2007	99501	99623	0.12%	99944	0.45%	99415	-0.09%	99481	-0.02%

各模型的不同评价结果如表 4 所示。从表可知 ACO-LSSVM 的各项指针要优于其它模型, 这说明采用 ACO 对 LSSVM 的参数进行优化可以更好地反映物流需求变化的趋势和规律, 有利于提高物流需求的预测精度, 预测结果更加稳定。同时从表 4 可知, ACO-LSSVM 参数搜索时间最短, 寻优速度更快, 说明采用 ACO 对 LSSVM 参数进行优化, 减少了计算时间, 加快算法收敛速度, 提高了物流需求的预测效率, 更具优越性。

表 4 物流需求预测模型的综合性能对比

评价指标	LSSVM	GA-LSSVM	PSO-LSSVM	ACO-LSSVM
RMSE	467.63	377.38	362.32	83.60
MAPE	0.54%	0.33%	0.39%	0.11%
TIME	50.457s	10.145s	5.097s	3.468s

综合上述可知, ACO 能够快速找到全局最优 LSSVM 参数, 有利于提高 LSSVM 学习和预测能力, 有效提高了物流需求的预测精度, 是一种有效的 LSSVM 参数优化方法。

5 结语

针对 LSSVM 参数优化问题, 提出了一种 ACO 优化 LSSVM 的物流需求预测模型。结果表明, 相对于其它预测模型, ACO-LSSVM 提高了物流需求的预测精度, 具有较高的实用价值。

参考文献

1 蔡临宁. 物流系统规划—建模及实例分析[M]. 北京: 机械工

业出版社, 2003. 6. 5-6

2 Garrido RA, Mahmassani S. Forecasting freight transportation demand with the space-time multinomial probity model. Trans on Research PartB, 2000, 34(5): 403-418.

3 Fite J, Taylor G, Usher J, et al. Forecasting freight demand using economic indices. International Journal of Physical Distribution & Logistics Management, 2001, 31(4): 99-102.

4 Fite J, Taylor G, Usher J, Roberts J. Forecasting freight demand using economic indices. International Journal of Physical Distribution & Logistics Management, 2001, 31(4): 299.

5 陈森, 周峰. 基于灰色系统理论的物流需求预测模型. 统计与决策, 2006(3): 59-60.

6 尹艳玲. 基于自适应神经网络的物流需求预测研究. 河南理工大学学报(自然科学版), 2010, 29(5): 700-704.

7 耿勇, 鞠颂东, 陈娅娜. 基于 BP 神经网络的物流需求分析与预测. 物流技术, 2007, 26(7): 35-37.

8 后锐, 张毕西. 基于 MLP 神经网络的区域物流需求预测方法及其应用. 系统工程理论与实践, 2005(12): 43-47.

9 胡燕祝, 吕宏义. 基于支持向量回归机的物流需求预测模型研究. 物流技术, 2008, 27(5): 66-68.

10 王丽华. 基于 GA-LSSVR 的图书馆文献资源需求预测. 计算机应用与软件, 2011, 28(6): 225-228.

11 Sumit T, Ongsakul W. Ant colony search algorithm for unit commitment. IEEE International Conference on Industrial Technology, 2003, 1(6): 72-77.